

Linear Regression

Regresyon katsayılarını bulmak için 2 yöntem kullanılır.

1) Ordinary Least Square:

- Non iterative Method
- Analytical Solution
- Not Scalable

2) Gradient Descent:

- Iterative Method
- Optimizasyon Algoritması
- Used for minimising Cost Function
- Birçok şeyi optimize etmek için kullanılır.

→ Daha önceki Gradient Descent'i nasıl kullandığımıza gördük. Bu analiz **OLS** ile yapılacak olup; Gradient Descent en sonunda ayrıca çok kısa bir şekilde anlatılacaktır.

1) Simple Linear Regression

$$e_i = y_i - \hat{y}_i; \text{ Sum of Squared Residuals} = e_1^2 + e_2^2 + \dots + e_n^2$$

$$= (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \dots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

The OLS approach chooses $\hat{\beta}_0$ and $\hat{\beta}_1$ to minimize the our Loss Function (Sum of Squared Residuals); Using some calculus it is shown that the minimizers are:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad \hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\text{Covariance}}{\text{Variance}}$$

OLS Solution

We can find how close $\hat{\beta}_0$ and $\hat{\beta}_1$ are to the True Values β_0 and β_1 . To compute the **Standard Errors** associated with $\hat{\beta}_0$ and $\hat{\beta}_1$, we use the following formulas:

$$SE(\hat{\beta}_0)^2 = \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right]; SE(\hat{\beta}_1)^2 = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

• Where $\sigma^2 = \text{Var}(\varepsilon)$.

→ Standard Errors can used to perform Hypothesis Tests on the Coefficients.

$$H_0 \Rightarrow \beta_1 = 0$$

$$H_1 \Rightarrow \beta_1 \neq 0$$

→ Değişkenin tek başına anlamlı olup veya olmadığını ölçeriz.

if $\beta_1 = 0$ then the model becomes $y_i = \beta_0 + \varepsilon$

$$t = \frac{\hat{\beta}_1 - 0}{SE(\hat{\beta}_1)} \Rightarrow \beta_1 \text{'in } 0 \text{ dan kaç standard smpa uzak olduğunu ölçer}$$

t value ile p-value'nun çok yakın bir ilişkisi vardır.

↓
 $\beta_1 = 0$ farz edildiğinde bulunan t değerine eşit veya daha büyük herhangi bir değer gözlemleme olasılığına p -value diyoruz.

↓
* t değeri arttıkça β_1 'in 0'dan uzaklaştığını biliyoruz.

* p value ise bize şunu diyor: $\beta_1 = 0$ iken bulunan "t" değerine eşit veya daha büyük bir t gözlemleme olasılığı. Ama biz $\beta_1 = 0$ iken "t" değerine çok küçük olmasını bekleriz. Yani "p olasılığı"; "t" büyük iken $\beta_1 = 0$ olma olasılığı vardır.

Simple Linear Regression

Problemni nasıl çözebiliriz? 1) OLS (Analytical Solution)

2) Least Squares Normal Equation (Matrix)

3) Optimization Algorithm (ex: Gradient Des)

2) Multiple Linear Regression

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_p x_p$$

The values $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$ that minimizes the **Loss Function** are the multiple least squares regression coefficient estimates

Sum of Squared Residuals

Multiple Linear Regression

Problemini nasıl çözebiliriz:

1) OLS (Analytical Solution)

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}_1 - \hat{\beta}_2 \bar{x}_2$$

$$\hat{\beta}_1 = \frac{(\sum x_2^2)(\sum x_1 y) - (\sum x_1 x_2)(\sum x_2 y)}{(\sum x_1^2)(\sum x_2^2) - (\sum x_1 x_2)^2}$$

$$\hat{\beta}_2 = \frac{(\sum x_1^2)(\sum x_2 y) - (\sum x_1 x_2)(\sum x_1 y)}{(\sum x_1^2)(\sum x_2^2) - (\sum x_1 x_2)^2}$$

Görüldüğü gibi 2 bağımsız değişkenli modelde bile çok fazla işlem var. Bu complex işlemlerden kurtulmak için problemi Matrix yaklaşımı ile çözeriz.

2) Least Squares Normal Equation (Matrix Form)

The Least Squares Normal Equation

can be expressed as:

$$X^T X b = X^T y$$

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \quad b = \begin{bmatrix} b_0 \\ b_1 \\ \vdots \\ b_k \end{bmatrix}$$

$$X = \begin{bmatrix} 1 & x_{1,1} & x_{1,2} & \dots & x_{1,k} \\ 1 & x_{2,1} & x_{2,2} & \dots & x_{2,k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n,1} & x_{n,2} & \dots & x_{n,k} \end{bmatrix}$$

$$\hat{y} = b_0 + \hat{b}_1 x_1 + \dots + \hat{b}_k x_k$$

3) Optimizasyon Algoritması (ex: Gradient Descent)

Data önce analiz edilmiştir.

Devam edelim;

Model overcall analizi:

$$H_0: \beta_1 = \beta_2 = \dots = \beta_p = 0$$

H_1 : at least one β_j is non-zero.

(F istatistiğinin de büyük olmasını isteriz)

$$F\text{-statistic} = \frac{\text{Açıklanan Varyans}}{\text{Açıklanmayan Varyans}} = \frac{SSR/k}{SSE/n-k-1}$$

→ P-value which is associated with F statistic is calculated. Based on this p-value, we can determine whether accept or reject H_0 .

↓
(Masıl ki "t istatistiğini" p-value ile yorumladık, aynı yorumu tamamen "F istatistiği" için de yapabiliriz.)

Gradient Descent üzerine;

Coefficient'ları iterative optimize eden ve amacı

Cost Function'ı minimize etmek olan algoritmadır.

(Masıl çalıştığı ile ilgili detaylı Gradient Descent bölümünde vermiştik)

↳ Each iteration updates $\beta_0, \beta_1, \dots, \beta_n$ to a line

that yields slightly lower error than the previous iteration.