

Maximum Likelihood, Likelihood, log-likelihood, Joint Prob

* Joint Probability \Rightarrow

ÖR Bir para 2 kez atılıyor } 2 adet rastgele değişken vardır.
Bir zar 1 kez atılıyor }

$X = \text{Paranın tura gelmelerinin sayısı} = \{0, 1, 2\}$

$Y = \text{Zarın 3 gelmelerinin sayısı} = \{0, 1\}$

Sonuç olarak $\Rightarrow P(X=0, Y=0) = 1/2 \times 1/2 \times 5/6$

$P(X=0, Y=1) = 1/2 \times 1/2 \times 1/6$

Yani 2 farklı rastgele değişkenin olasılıklarına ait probabilitydır.

(ortak olasılık dağılımı)
Joint Probability Distribution

↓
2 rastgele
Değişken

(2 rastgele değişkenin aynı anda
gerçekleşmelerinin olasılığı)

↙ Continuous

↘ Discrete

Probability Distribution

↓
1 rastgele Değişken

↙ Continuous

↘ Discrete

İstatistik, any value that is calculated from a given sample.

"Max Likelihood" tüm dağılımlarda model parametrelerini optimize etmeye çalışır.

Ör: Exponential bir dağılımda λ 'ya

Normal bir dağılımda σ veya μ 'ni gibi.

Örnek ile gidelim

Amaçımız, elimizde bulunan verilerin ait olduğu yığılı (popülasyon)

tahmin etmektir. Çünkü genelde popülasyona ait parametrenin

gerçek değerini bilmiyoruz bir hayli zordur. Maximum Likelihood

uygulanabilecek çözümlerden bir tanesidir.

"Olabirliklik Fonksiyonu" genelde Kesikli ve Sürekli olasılık dağılımları için farklı şekilde tanımlanır.

— Mesela; Discrete Durumda

$$P(HH | p_H = 0.5) = 0.5^2 = 0.25$$

Yani adil bir para olduğunda Tura gelme olasılığımız = 0.5

olacak. 2 kez para atıldığında "HH" gelme olasılığımız 0.25 olacaktır.

Likelihood ise;

$L(p_H = 0.5 | HH) = 0.25$ » Given the observed data "HH", the likelihood that the model parameter $p_H = 0.5$ is 0.25.

Yani; for each value of p_H , we can calculate the corresponding likelihood.

Discrete Durumda: Likelihood, parametrenin gerçek

$X=x$ Random Variable

değeri θ olduğunda x outcome'ın gözlenme olasılığıdır. ($\theta = p_H$ oldu bu case'de)

Yani; $P(HH | p_H = 0.3) = 0.3^2 = 0.09$ Unfair Para

$$L(p_H = 0.3 | HH) = 0.09$$

Continuous Durumda: Likelihood, parametrenin


$X=x$ Random Variable

$$L(\theta | x)$$

gerçek değeri θ olduğunda x outcome'ın olasılık yoğunluğuna eşittir.

Bu durumda $\theta =$

σ, μ olabilir.



Assume mean = 32, sd = 2.5

$$\Rightarrow L(\text{mean} = 32 \text{ and } sd = 2.5 | \text{mouse weight } 34 \text{ gr})$$

The likelihood of distribution with mean = 32,

s.d = 2.5 given mouse with weight 34 gr

$$is = 0.12.$$

* Amaç ne demiştik? Popülasyon parametrelerini tahmin etmek.

Beel bir örnekle Gidelim

Popülasyondan çekilmiş X_1, X_2, \dots, X_n örnekleri olsun

elimizde. Varsayımımız şu olmalı: Örnekler birbirinden bağımsız.

Popülasyona ait dağılım tipini biliyoruz (Normal olsunlar)

$$\underbrace{L(\theta | x_1, x_2, \dots, x_n)}_{\text{Likelihood Function}} = L(\theta | x_1) \times \dots \times L(\theta | x_n)$$

Likelihood Function

Bilinen x 'lere karşı bilinmeyen θ parametresinin

$$\text{uygulanması} = L(\theta | x_1, x_2, \dots, x_n)$$

Bu fonksiyonu maksimum

yapmak için $L(\theta)$ 'nin θ parametresine göre türevi alınmalı.

$L(\theta)$ 'nin e tabanına göre logaritmasını alalım.

$$\ln L(\theta) = \ln(p(x_1|\theta) \cdot p(x_2|\theta) \cdot \dots \cdot p(x_n|\theta))$$

$$= \ln p(x_1|\theta) + \ln p(x_2|\theta) + \dots + \ln p(x_n|\theta)$$

$$\text{Log-likelihood} \Rightarrow \sum_{k=1}^n \ln p(x_k|\theta)$$

Kısaca çarpma işlemini toplamağa çevirdik, böylece

türev aşamasında işler kolay olsun.

Daha sonra $\sum_{k=1}^n \ln p(x_k|\theta)$ 'nin θ 'ya göre türevi alınacak

$\ln L(\theta)$ 'yi maksimum yapan θ değeri bulunur.

Kıtaç Açıklaması: Maksimum Olabilirlik Yöntemi, Bayes

Çıkarımına aksine, parametreleri sabit

bir nokta olarak görür. Yani yapılan işlemler

sonucunda çıkarılacak sonuç sabit bir sayıdır.

$X = \{x^t\}_{t=1}^N$, x^t are instances (gözlemlenimler) drawn from some known probability density family ($p(x|\theta)$).

$$x^t \sim p(x|\theta)$$

$$\text{Likelihood func} \rightarrow L(\theta|X) \equiv p(X|\theta) = \prod_{t=1}^N p(x^t|\theta)$$

$$\text{Log-likelihood func} \rightarrow \mathcal{L}(\theta|X) \equiv \log L(\theta|X) = \sum_{t=1}^N \log p(x^t|\theta)$$

Pot; We want to find θ that makes sampling x^t
 from $p(x|\theta)$ as likely as possible. Because x^t are
 independent, the likelihood of parameter θ ; given
 sample X is the product of the likelihoods of individual
 points: $\mathcal{L}(\theta|X) \equiv \underbrace{p(X|\theta)}_{\text{prob density for continuous dist. ;}} = \prod_{t=1}^N p(x^t|\theta)$
 prob Mass for Discrete Dist.