

Bayesian Estimation vs Maximum Likelihood Estimation

Parameter Estimation: Observed data x depends on unknown parameters α through pdf

$$x \sim f(x; \alpha)$$

Brief MLE

log-likelihood Estimation $\Rightarrow L(\theta) = \log P(\text{Data} | \theta)$

So, θ is estimated by maximizing the log-likelihood

Yani $\Rightarrow \theta_{MLE} = \arg \max_{\theta} L(\theta)$

Bayesian Estimation:

Given model $f(x|\alpha)$ and prior $f(\alpha)$,
find posterior pdf $f(\alpha|x)$


$$\text{Bayes's Rule: } f(\alpha|x) = f(x|\alpha) \cdot f(\alpha) / f(x)$$

Ne demektik? Frequentists use MLE to obtain a
point estimation of the parameters θ .

Instead of Point Estimate, Bayesians
estimate full posterior distribution of
the parameters using Bayes formula.

$$P(\theta | \text{Data}) = \frac{P(\text{Data} | \theta) P(\theta)}{P(\text{Data})}$$

Bu ne demek?



Yani; Bayesyen
parametrelere ait
Posterior dağılımı
tahmin eder.

(Aslında parametreye ait
dağılımı tahmin ediyoruz)

Peki birçok muhtemel θ değeri varken en iyisini
nasıl bulacağız?

Bu durumda, aklımıza MLE'nin yaptığı gibi bir point estimate yapabilir miyiz diyoruz.

Tam bu noktada Maximum A Posteriori (MAP) estimation devreye girer.

Tries to find point estimates of θ that maximize the Posterior Distribution.

$$\theta_{MAP} = \arg \max_{\theta} P(\theta | \text{Data})$$

Bayes Ağları (Bayesian Network)

Koşullu olasılık formülü: ① $P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$

* $P(A \cap B) = P(B|A)P(A) = P(A|B)P(B)$ ② $P(A|B) = \frac{P(A \cap B)}{P(B)}$

Ör. Yay üreten 3 makine için bozuk ve üretim oranları veriliyor. Eğer yay bozuk ise 3. makineden çıkma olasılığı nedir?

		Bozuk %	Üretim oranı %
1. makine	2	35	
2. "	1	25	
3. "	3	40	

$P(B) =$

$$P(B) = \frac{35}{100} \cdot \frac{2}{100} + \frac{25}{100} \cdot \frac{1}{100} + \frac{40}{100} \cdot \frac{3}{100} = \frac{215}{10000}$$

$$P(3. \text{ makine} | B) = \frac{P(3. \text{ mak.}) \cdot P(B|3. \text{ mak.})}{P(B)} = \frac{\frac{40}{100} \cdot \frac{3}{100}}{\frac{215}{10000}} = \frac{120}{215}$$

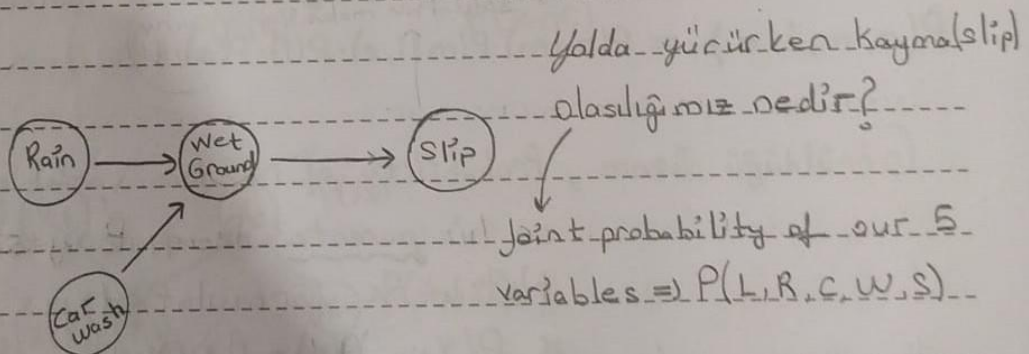
If X and Y are dependent events, then conditional probability is $\Rightarrow P(X|Y) = P(X \cap Y) / P(Y)$

If X and Y are independent, then conditional prob is $\Rightarrow P(X|Y) = P(X)$

* Joint Probability $\Rightarrow P(A, B, C) \rightarrow$ The probability of event A, B, C occur at the same time. (Besişimleri yani)

* $P(A \cap B) = P(A, B)$

ÖR. Bayesian Network:

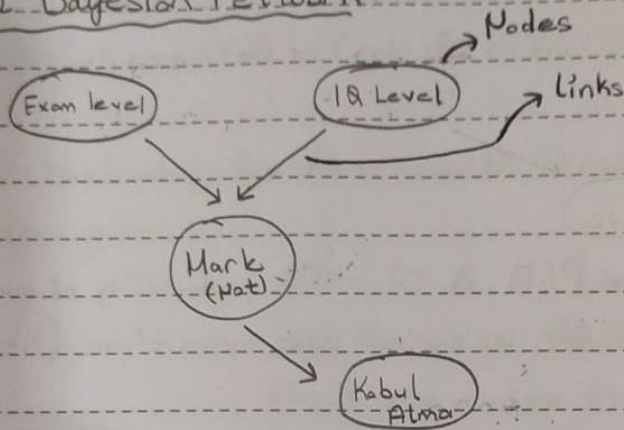


Joint probability of our 5 variables $\Rightarrow P(L, R, C, W, S)$

$$P(R, C, W, S) = P(R)P(C)P(W|C, R)P(S|W)$$

Bayes Ağları "Parents" mantığı ile çalışır. Arka sayfada açıklanacak.

Örnek Bayesian Network



Öğrencinin kabul alma

olasılığını bulacağız.



Calculate the joint prob. of these 5 variables.

$$P(a, m, i, e) = P(a|m) \cdot P(m|i, e) \cdot P(i) \cdot P(e)$$

Görüldüğü üzere, Probability of random variable depends on his parents. Therefore, Bayesian Network formulated as;

$$* P(X_1, \dots, X_n) = \prod_{i=1}^n P(X_i | \text{Parents}(X_i))$$

Yani; Örneğin;

- Öğrencinin "Mark"ı Exam level (Parent node) ve IQ Level (Parent node)'e bağlıdır.


- Öğrencinin kabul alması da Mark'a (Parent Node) bağlıdır.

Sonuç olarak;

Bir düğümün (Node) gerçekleşme olasılığı

önceki düğümlerin ortak (joint) olasılığına bağlıdır

Bana söyle bir
örnek verseydi:




Kaza olasılığını z P edic?

$$P(y, s, k) = P(k | y, s) \cdot P(y) \cdot P(s)$$

Bunların
parent' yok.

$$\text{Ek: } P(A|B, C) = \frac{P(A \cap B|C)}{P(B|C)} = \frac{P(A \cap B \cap C)}{P(B \cap C)}$$

(EK)




Ayrıca

$$P(H|B) = \frac{P(B|H) \cdot P(H)}{P(B)}$$

$\Rightarrow P(B)$ olasılığı H olduğu ve
olmadığı durumlardaki olasılıkların
toplamına eşittir

$$P(H|B) = \frac{P(B|H) \cdot P(H)}{P(B|H) \cdot P(H) + P(B|\bar{H}) \cdot P(\bar{H})}$$

Bayes Ağı Son Örnek



Çimlerin ıslak olma olasılığı? $P(r, s, g) = P(g|r, s) \cdot P(s|r) \cdot P(r)$