


# XGBoost

## a) Regression :

Örneği kolay anlatmak için super simple bir training set kullanacağız.



1) The first step in fitting

XGBoost to the Training Data

is to make initial prediction.

Bu initial olarak bir sayı olabilir. Herkes Default'de her

Regression her Sigmoidness için 0.5 alıyor.

2) Calculate first (initial) residuals. Difference between Observed and Predicted values.

3) Tüm ağaçlar single leaf ile başlar. Bu single leaf'te ilk olarak Residualler olur.

4) Bu residualler için "Similarity Score" hesaplanır.

$$\text{Similarity Score} = \frac{(\text{Sum of the Residuals})^2}{\text{Number of residuals} + \lambda} \quad \lambda \rightarrow (\text{Regularization parameter})$$

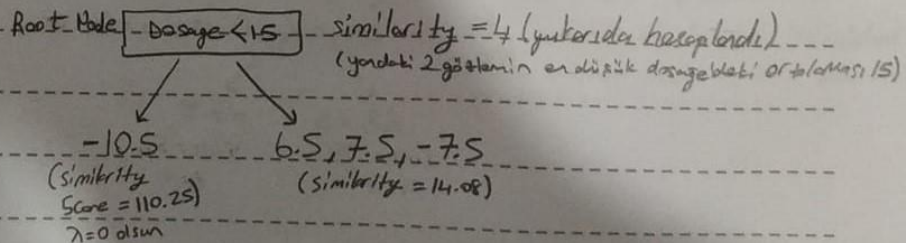
$-10.5, 6.5, 7.5, -7.5$

→ ilk leaf ilk residualler ile başlar demektir.

$$\text{Sim. score} = \frac{(-10.5 + 6.5 + 7.5 - 7.5)^2}{4 + \lambda} \rightarrow \text{olsun similitik}$$

5) İlk leaf similarity = 4 oldu. Şimdi bunu düşünelim, Residualleri 2 gaba bölersek daha iyi cluster etmiş olur muyuz.-----

b) Bunun için ilk leaf node'u en iyi bilecek Dosage (x) karar vermek lazım. En iyi demek en fazla "Gain" sağlayacak demek. Bunun için Bağımsız değişkenin en küçük 2 değerinin ortalamasını alarak denemeye başlarız ve her denemede bir sonraki 2 gözlemin ortalamasını alarak leaf deneyir.



$\lambda = 0$  dsm

Gain = Left simibity + Right sim - Root sim  $\Rightarrow 110.25 + 14.08 - 4 = 120.33$

Now, we calculated the **Gain** for the threshold "Dosage < 15", we can compare it to the "Gain" calculated for other Thresholds.

→ Dosage < 15, Dosage < 22.5, Dosage < 30 Gain'lerine bakılır. En yüksek Gain veren Root olarak seçilir. Bu örnekte en yüksek Gain Dosage < 15 iken oluyor.

Dosage < 15

-10.5

(Burada tek Residual olduğu için, we can't split it any further).

$\lambda = 0$

6.5, 7.5, -7.5 → similarity = 14.08

(Burası split edilir)

22.5 için: Bu durumda; split edilecek node için yine yukarıdaki gibi threshold'lar denemeye başlarız.

Dosage < 15

-10.5

Dosage < 22.5 (ilk olarak 22.5 denesim)

6.5

(similarity = 42.25)

7.5, -7.5

(similarity = 0)

$$\text{Gain} = 42.25 + 0 - 14.08 = 28.17$$

30 için:

Dosage < 15

-10.5

Dosage < 30 → sim = 14.08

6.5, 7.5

sim = 98

$\lambda = 0$

-7.5

sim = 56.25

$\lambda = 0$

$$\text{Gain} = 98 + 56.25 - 14.08 = 140.17 \quad \text{Dosage 30 seçildi.}$$



7) Tree'yi Prune etme i.  $\gamma(\text{gamma}) = 130$  olsun diyalim.

\*  $\text{Gain} - \gamma(\text{gamma}) < 0$  ise, we remove the Branch.

Mesela  $\rightarrow$  Dosage  $< 30$  olduđu durumda  $\text{Gain} = 140.17$  idi.

0 node'u remove edemeyiz çünkü  $140.17 > 130$ .

8)  $\lambda = 0$  aldık hep işlen kolaylığı için.  $\lambda \rightarrow$  Regularization

parameter and reduce the prediction's sensitivity to individual

observations. "1" When  $\lambda > 0$ , the similarity scores are

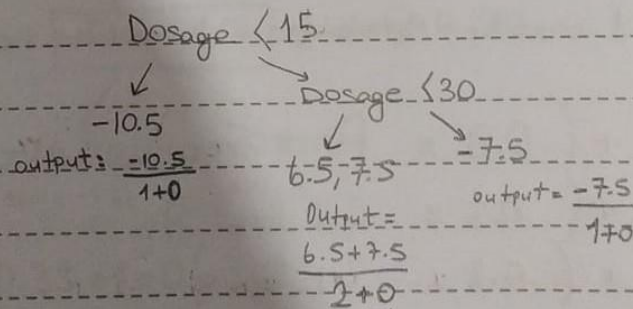
smaller. "2" When  $\lambda > 0$ , the Gain values are smaller

also."

$\lambda \rightarrow$  Training Data'da overfit'i engeller.

9) Leaf Output Value =  $\frac{\text{Sum of Residuals}}{\text{Number of Residuals} + \lambda}$

Yani ;



$\lambda > 0$  olduğunda, it reduce

the amount that this individual observation adds to the overall prediction.

10) Bu durumda, örneğin;

New Predicted value for observation with Dosage = 10  
is calculated as follows:

$$\text{Original Prediction} + (\text{Learning Rate} \times -10.5)$$

$$0.5 + 0.3 \times \begin{matrix} \text{Dosage} < 15 \\ \swarrow \\ -10.5 \\ \text{output} = -10.5 \\ \lambda = 0.1 \text{ then} \end{matrix} = -2.65$$

(new prediction)

★ New residual is smaller than the previous (initial) residual.

8) Aynı şekilde; New prediction for observation with Dosage = 20

$$0.5 + (0.3 \times 7) = 2.6$$


↳ New residual is smaller than before again.

11) Build another tree based on the newest "Residuals".

$$\begin{aligned} &0.5 + (0.3 \times \text{First Tree}) \\ &+ (0.3 \times \text{2nd Tree}) \\ &+ (0.3 \times \text{3rd Tree}) \end{aligned}$$

## b) Classification:

Regression for binary



$$\text{Similarity Score for Residuals} = \frac{(\sum \text{Residuals}_i)^2}{\sum [\text{Previous Prob}_i \times (1 - \text{Previous Prob}_i)] + \lambda}$$

Origin

$$[-0.5, 0.5, 0.5, -0.5] \rightarrow \text{similarity} = 0$$


$$\text{Dosage } \{15\} \rightarrow \text{similarity} = 0 \text{ id}$$

$$\begin{array}{cc} -0.5, 0.5, 0.5 & -0.5 \\ \text{sim} = 0.33 & \text{sim} = 1 \end{array}$$

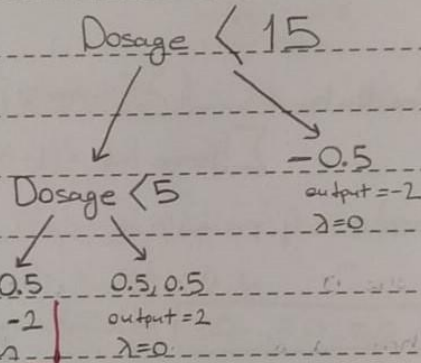
$$\text{Gain} = 0.33 + 1 - 0 = 1.33$$



Olusan ilk ağacımız aşağıdaki gibi olsun:



$$\text{Output value for a leaf} = \frac{(\sum \text{Residuals})}{\sum [\text{Previous Prob}_i \times (1 - \text{Previous Prob}_i)] + \lambda}$$



$$\left( \frac{p}{1-p} = \text{odds} \right)$$

Örneğin

"New Predicted" value for observation whose Dosage=2:

Predicted Drug Effectiveness

$$\text{Initial} = 0.5 + \left( \overset{\text{learning rate}}{0.3} \times \overset{\text{output}}{-2} \right) = -0.6$$

$$\rightarrow \log(\text{odds}) = 0$$

→  $\log(\text{odds}) = -0.6$  Convert  $\log(\text{odds})$  into probability.

Use Logistic Func

$$\text{Probability} = \frac{e^{-0.6}}{1 + e^{-0.6}} = 0.35$$

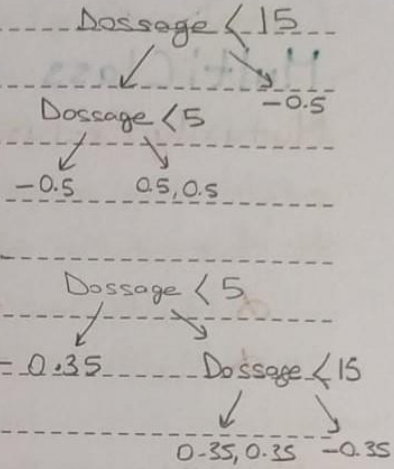
→ Original residual was -0.5, with new prediction it becomes -0.35.

### Gösterim 3

Initial Prediction = 0.5

$\log(\text{odds}) = 0$

+ 0.3 x



### OPTIMIZATIONS 3

- Large dataset olduğunda bir node karar vermek için, her farklı değişkenin her threshold değerine bakmak çok maliyetli.
- Yani, Değişken X için tek tek arka arkaya gelen her 2 gözlemin ortalamasına bakıp en iyi threshold buluyor idik ve bunu tüm değişkenler (Y, Z...) için yapıyorduk. Large dataset olduğunda thresholdları quantile noktalardan seçer. XGBoost, böylece bakması gereken threshold sayısını azaltmış olur.

### How Xgboost Deal with Missing Values?

- Training kümesinde missing değerlerin sağ veya sol node'dan hangisine gideceğine loss'u minimize etmesi bakımından karar verir ve test kümesindeki missing değerler a node'a gider default olarak. Training kümede NaN yok ise bu durumda her node için Default missing yönü seçer ve Test için bu yön kullanılır.